CLINC150 实验报告

查询自适应示例选择 | 8-shot ICL | 2026年11月13日

关键结论

TabPFN-v2 在官方 Test 上达到 91.333%，比 Similar 多答对 12 条（+0.267 个百分点），但准确率提升未达到统计显著。Validation 预先选定的固定 Balanced 为 91.533%，仍比 TabPFN 多答对 9 条。本轮确认了策略切换现象，尚未确认自适应选择优于固定策略的可靠优势。

实验设置

仅使用官方 CLINC150 的 150 个 in-scope 意图，排除全部 OOS。Train 15,000 条按 seed=42 分层划分为 Demo 10,000 条与 Meta-training 5,000 条；官方 Validation 3,000 条、Test 4,500 条保持不变。

冻结 Qwen2.5-1.5B-Instruct，采用 MPS FP16 与 greedy 解码；all-MiniLM-L6-v2 编码，cosine 检索 Top-32，统一选取 8 条示例。Similar 选最相关示例；Diverse 使用 MaxMin；Balanced 使用 MMR（λ=0.5）。LR 与 TabPFN-v2 重新在 CLINC150 上拟合，沿用四个邻域特征及 gold-label 平均 token log-likelihood 元标签。

模型与路由决策在 Test 评价前封存；固定基线按 Validation 选定。严格解析完整标签，invalid 一律记错，不截断提示。

主要结果

方法	Val Acc.	Test Acc.	Test F1	Test 正确数	Invalid
Similar	91.667%	91.067%	0.90995	4098/4500	20
Diverse	92.200%	91.044%	0.91061	4097/4500	21
Balanced	92.467%	91.533%	0.91572	4119/4500	18
LR Adaptive	92.333%	91.267%	0.91222	4107/4500	20
TabPFN-v2	91.833%	91.333%	0.91279	4110/4500	20
Oracle 上界*	94.367%	94.133%	0.94176	4236/4500	12

Acc. 为 Accuracy；F1 为覆盖全部 150 类的 Macro-F1；Invalid 列为 Test 无效输出条数。Balanced 在两个 split 均为数值最佳的可部署方法，这不等同于已证实统计优胜。

* Oracle 使用 gold 事后逐题选策略，只作分析上界，不可部署。其 F1/invalid 来自固定见证规则：正确 Similar 优先，其次 Balanced、Diverse，全部失败则 Similar。

策略切换与统计结论

自适应行为与实际收益

选择器	S / D / B 次数	有益 / 有害 / 中性切换	相对 Similar
LR	1248 / 1744 / 1508	78 / 69 / 3105	+9 条
TabPFN-v2	2789 / 0 / 1711	26 / 14 / 1671	+12 条

S / D / B 分别指 Similar / Diverse / Balanced；切换的有益、有害与中性均相对 Similar 定义。

TabPFN 在 38.02% 的查询上切换到 Balanced，没有选择 Diverse。1711 次切换中，1671 次（97.66%）未改变对错状态。它已摆脱原始 Banking77 的全 Similar 输出，但“会切换”并不等于“有可靠收益”。

Test 的 Oracle 为 94.133%，比 Similar 多对 138 条，余量为 3.067 个百分点。TabPFN 挽救其中 26 条，却损失 14 条原本正确的查询，净兑现 Oracle 余量约 8.70%。

配对统计

比较	Δ Acc. 百分点	95% 配对 CI 百分点	McNemar p	Holm p
TabPFN - Similar	+0.267	[0.000, +0.556]	0.08069	0.72621
TabPFN - Balanced	-0.200	[-0.711, +0.311]	0.50660	1.00000
LR - Similar	+0.200	[-0.333, +0.733]	0.50950	1.00000

采用 5,000 次查询级 paired bootstrap（seed=42）、双侧精确 McNemar；每个 split 的 5 个可部署方法共 10 个两两比较构成 Holm 校正家族。主要 Accuracy 比较未显著；区间下端为 0 不能解释为已确认提升。

结果解释与结论

收益受限的直接现象是策略间正确性高度一致：93.96% 的 Test 查询三策略全对或全错。训练中另有 76.88% 的查询，最佳与次佳策略似然差≤0.001；这种弱分离，加上似然目标与 greedy 正确率的错位，可能限制四特征选择器的泛化，但目前不能作单一因果归因。

与原始 Banking77 相比，Oracle 余量仅从 2.922 增至 3.067 个百分点，TabPFN 从零增益变为小幅数值增益，尚不足以证明策略互补变得更可预测。跨数据集仅作描述性对照。当前优先保留 Validation 选定的固定 Balanced，后续用新数据或多 seed 独立验证自适应的额外价值，不依据本 Test 继续调参。

边界与完整性：单个 seed、单个 LLM；存在 52 对规范化跨分区重复及 4,061 对词面近重复，已披露并保留官方分区。全部 37,500 条评分/预测记录已核验，168 项测试通过，原 Banking77 文件未改。

依据：本项目 test_metrics.csv、validation_metrics.csv、paired_comparisons.csv、meta_label_diagnostics.json 与 verification.json。完整中文报告见同目录 summary.md。

代码与结果：DSAI4207_Adaptive_TFM 仓库