HWU64 意图分类中的查询自适应示例选择

HWU64 · 8-shot In-Context Learning
数据版本：0dd289ccdeb185ec065d1ebcf5de1c443cd1620f · Seed=42

研究问题：冻结 Qwen 模型时，能否根据查询的检索统计特征，由 Logistic Regression / TabPFN-v2 在 Similar、Diverse、Balanced 三种 8-shot 策略之间进行选择？

最佳固定策略	Logistic Regression	TabPFN-v2	Oracle 上界
Balanced	86.431%	85.037%	85.037%
			90.056%

执行摘要

官方 Test 包含 1,076 条 query。固定策略中 Balanced 准确率最高（86.431%）。LR 为 85.037%，TabPFN-v2 为 85.037%。Oracle 为 90.056%，只表示事后上界，不能部署。

Meta-training 监督标签采用三种策略的真实 0/1 分类正确性；标签分布为 {'similar': 1712, 'balanced': 59, 'diverse': 20}。这与原 Banking77 报告使用 token log-likelihood 的方法不同。

数据划分：Demo Pool 6,268；Meta-training 1,791；Validation 895；Official Test 1,076。

01 研究方案与实验流程

任务是将个人助理/智能家居场景中的英文用户 utterance 分类到 HWU64 的 64 个 intent。Qwen2.5-1.5B-Instruct 全程冻结；Sentence-BERT 仅用于语义检索。

步骤	实现
数据	DeepPavlov/hwu64；8,954 train / 1,076 test
向量	all-MiniLM-L6-v2；L2-normalized embeddings
检索	cosine Top-32；排除相同规范化文本
示例选择	Similar / Diverse (greedy MaxMin) / Balanced (MMR $\lambda=0.5$)；k=8
分类	Frozen Qwen2.5-1.5B-Instruct；greedy decoding
Meta-selector	4 retrieval features；Logistic Regression / TabPFN-v2

Meta-selector 的四维输入是 Top-32 最大相似度、平均相似度、候选标签分布熵、候选多数标签占比。它们不包含当前 query 的 gold label。

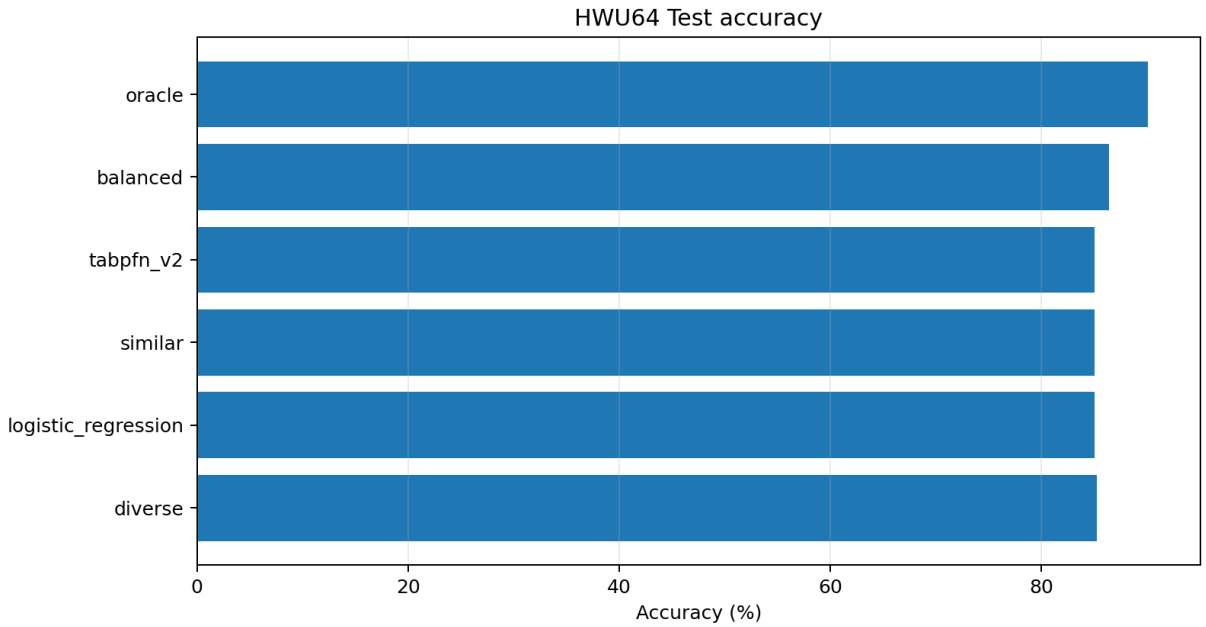
监督标签构造

对每条 Meta-training query，分别运行三种策略，并将真实分类正确的策略作为正向目标；多种策略均正确或全部错误时按 Similar > Balanced > Diverse 固定顺序打破平局。Validation/Test 的 gold label 不参与 selector 训练。

与原报告的关键区别：本版本把 meta-label 与最终 0/1 accuracy 对齐，不再用 gold-label token log-likelihood 最大值作为训练目标。

02 官方 Test 最终结果

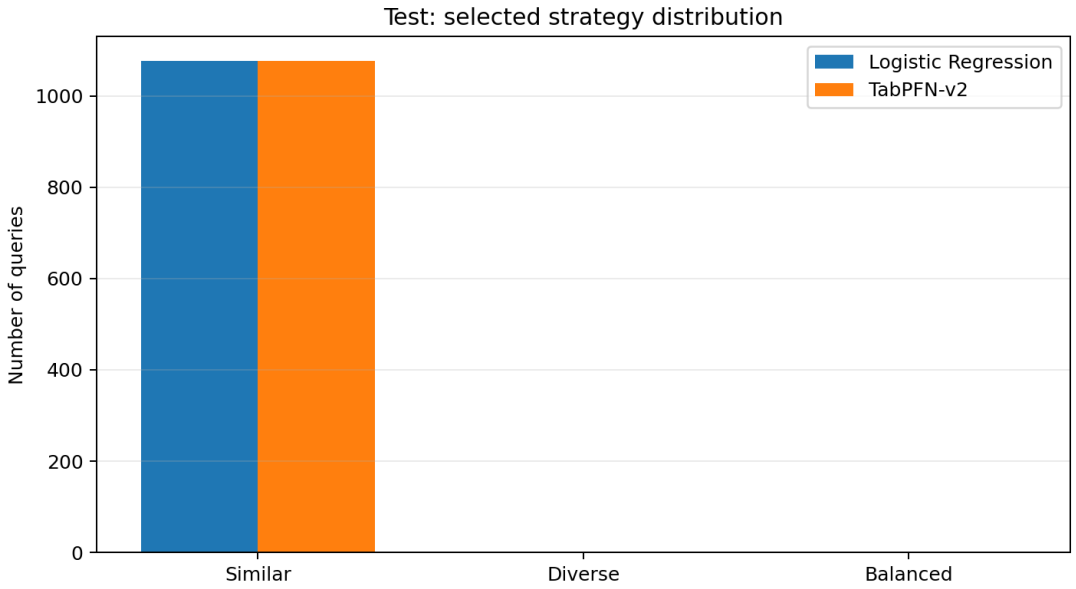
方法	正确数	Accuracy	Macro-F1	Invalid
Similar	915/1,076	85.037%	0.83237	6
Diverse	917/1,076	85.223%	0.84133	7
Balanced	930/1,076	86.431%	0.85130	6
Logistic Regression	915/1,076	85.037%	0.83237	6
TabPFN-v2	915/1,076	85.037%	0.83237	6
Oracle（事后上界）	969/1,076	90.056%	0.89085	2



解读：Oracle 的每条 query 都在观察三种策略的真实正确性后选择，因此是不可部署的 retrospective upper bound。不能将其作为模型结果。

03 策略切换与 Oracle 空间

选择器	策略选择分布	有益切换	有害切换	净增正确
LR	{'similar': 1076}	0	0	+0
TabPFN-v2	{'similar': 1076}	0	0	+0



在 Meta-training 中，1,634 条 query 至少有一个策略分类正确；157 条 query 的三个策略全部错误。选择器是否学会切换，必须结合有益/有害切换数，而不能只看它输出了不同策略。

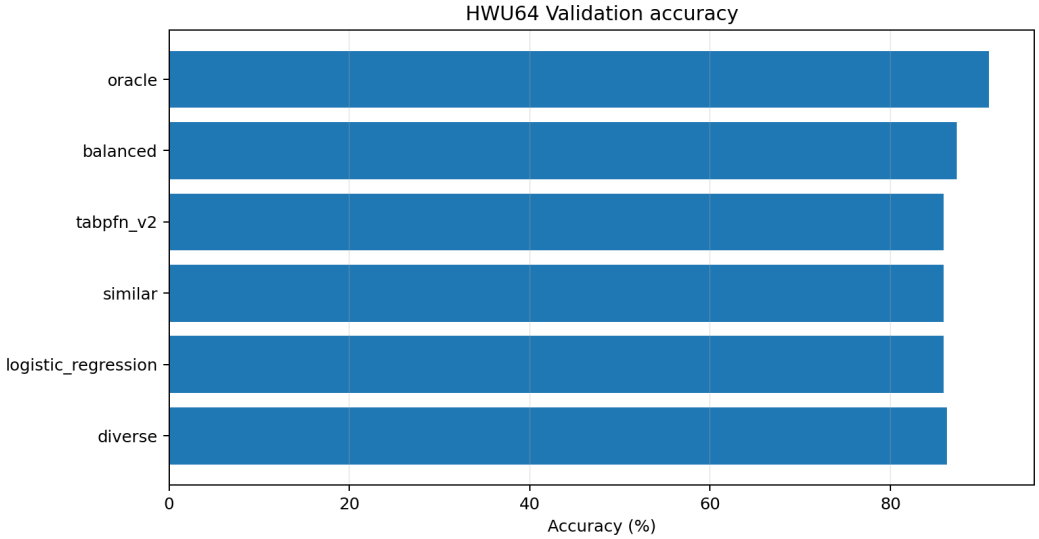
04 配对统计检验

使用 Query-level paired bootstrap（固定 seed；5,000 次重抽样）估计 Accuracy 差值的 95% 置信区间；采用双侧 Exact McNemar 检验，并对四个相对 Similar 的比较进行 Holm 校正。

比较	Δ Accuracy (pp)	95% Bootstrap CI	McNemar p	Holm p
diverse - similar	+0.186	[-1.487, +1.952]	0.9152	1.0000
balanced - similar	+1.394	[-0.093, +2.974]	0.0959	0.3837
logistic_regression - similar	+0.000	[+0.000, +0.000]	1.0000	1.0000
tabpfn_v2 - similar	+0.000	[+0.000, +0.000]	1.0000	1.0000

Validation 与 Official Test

方法	Validation	Test	Test - Val (pp)
Similar	85.922%	85.037%	-0.885
Diverse	86.257%	85.223%	-1.034
Balanced	87.374%	86.431%	-0.943
Logistic Regression	85.922%	85.037%	-0.885
TabPFN-v2	85.922%	85.037%	-0.885
Oracle（事后上界）	90.950%	90.056%	-0.894



05 讨论、局限与可复现性

结果解释边界

1. 本次结果只适用于 HWU64 当前数据快照、指定 Qwen checkpoint、all-MiniLM-L6-v2 与三种固定的 8-shot 选择策略。

2. 直接 correctness meta-label 与最终 accuracy 更一致，但容易受 Similar
已经较强、三策略预测高度重合及标签类别不平衡影响。应检查 meta_label_diagnostics.json。

3. Selector 训练诊断：{'logistic_regression': {'best_params': {'clf__C': 0.1}, 'cv_folds': 5, 'cv_best_macro_f1': 0.32581590305223207}, 'tabpfn': {'device': 'mps', 'version': 'v2', 'n_estimators': 4, 'checkpoint': {'repository': 'Prior-Labs/TabPFN-v2-clf', 'revision': '275f19d2add9c2c0de38f9ebaded3856599fa2e7', 'filename': 'tabpfn-v2-classifier-finetuned-zk73skhh.ckpt', 'sha256': 'cf8c519c01eaf1613ee91239006d57b1c806ff5f23ac1aeb1315ba1015210e49'}, 'n_training_rows': 1791, 'class_counts': {'0': 1712, '1': 20, '2': 59}, 'saved_fit_context': 'models/tabpfn_fit_context.npz', 'package_version': '8.0.7'}}。若 meta-target 只有一个类别，程序会明确记录 majority-class fallback，而不会伪称训练出了可切换的多类 selector。

4. Oracle 是使用 gold label 事后挑选策略的上界，不代表实际系统可以达到。

5. Test 结果只可用于最终评估，不应用来反复调参或重新选阈值。

可复现性记录

项目	记录
Dataset	DeepPavlov/hwu64 @ 0dd289ccdeb185ec065d1ebcf5de1c443cd1620f
Split	seed=42；70/20/10 stratified train split
Embedding	sentence-transformers/all-MiniLM-L6-v2 @ 1110a243fdf4706b3f48f1d95db1a4f5529b4d41
LLM	Qwen/Qwen2.5-1.5B-Instruct @ 989aa7980e4cf806f80c7fef2b1adb7bc71aa306
Selection	Top-32; k=8; MMR λ=0.5
Selector	LR + pinned TabPFN-v2 checkpoint

主要输出：results/evaluation.json、results/meta_training_dataset.csv、validation/test predictions CSV、cache/predictions/ 和本 PDF 报告。