HWU64 意图分类中的查询自适应示例选择

HWU64 · 8-shot In-Context Learning
数据版本：local-arrow-cache-0dd289ccdeb185ec065d1ebcf5de1c443cd1620f · Seed=42

研究问题：冻结 Qwen 模型时，能否根据查询的检索统计特征，由 Logistic Regression / TabPFN-v2 在 Similar、Diverse、Balanced 三种 8-shot 策略之间进行选择？

最佳固定策略	Logistic Regression	TabPFN-v2	Oracle 上界
Balanced	85.967%	85.223%	86.059%
			89.870%

执行摘要

官方 Test 包含 1,076 条 query。固定策略中 Balanced 准确率最高（85.967%）。LR 为 85.223%，TabPFN-v2 为 86.059%。Oracle 为 89.870%，只表示事后上界，不能部署。

Meta-training 监督标签沿用 Banking77 方法：在三种策略提示下，对该 query 的 Gold Intent continuation 计算 token 平均 log-likelihood（不含 prompt 和 EOS），取分数最高的策略；标签分布为 {'similar': 576, 'diverse': 577, 'balanced': 638}。

数据划分：Demo Pool 6,268；Meta-training 1,791；Validation 895；Official Test 1,076。

01 研究方案与实验流程

任务是将个人助理/智能家居场景中的英文用户 utterance 分类到 HWU64 的 64 个 intent。Qwen2.5-1.5B-Instruct 全程冻结；Sentence-BERT 仅用于语义检索。

步骤	实现
数据	DeepPavlov/hwu64；8,954 train / 1,076 test
向量	all-MiniLM-L6-v2；L2-normalized embeddings
检索	cosine Top-32；排除相同规范化文本
示例选择	Similar / Diverse (greedy MaxMin) / Balanced (MMR $\lambda=0.5$)；k=8
分类	Frozen Qwen2.5-1.5B-Instruct；greedy decoding
Meta-selector	4 retrieval features；Logistic Regression / TabPFN-v2

Meta-selector 的四维输入是 Top-32 最大相似度、平均相似度、候选标签分布熵、候选多数标签占比。它们不包含当前 query 的 gold label。

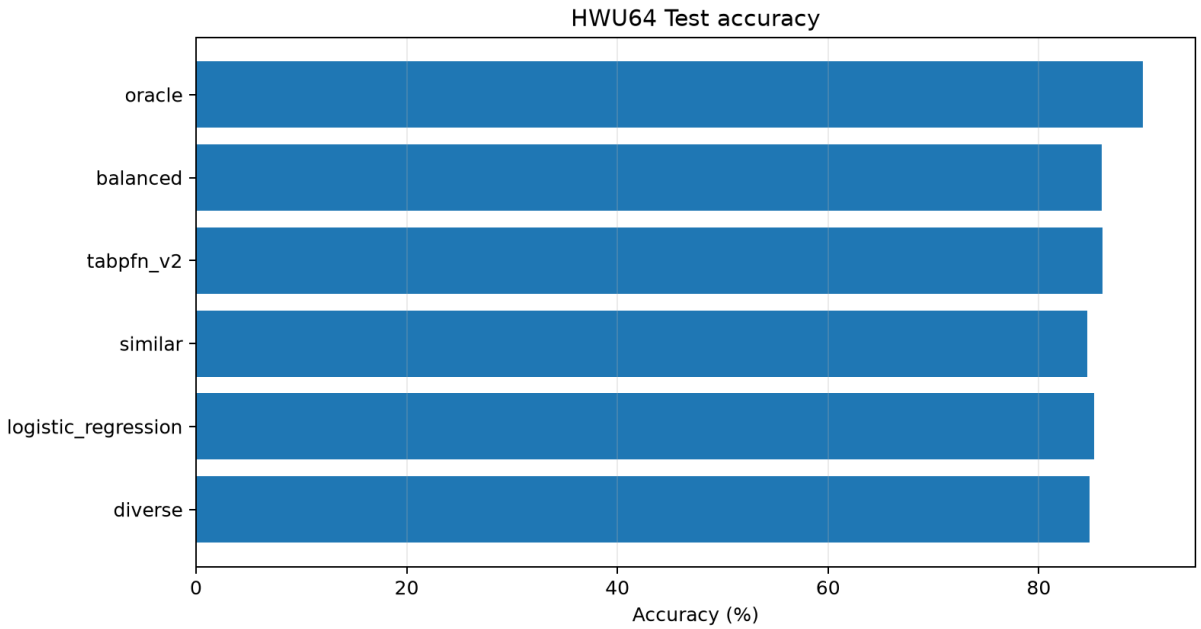
监督标签构造

对每条 Meta-training query，在 Similar、Diverse、Balanced 三种策略下分别构造同一分类提示，并对该 query 的 Gold Intent continuation 进行 teacher-forced scoring；按 label token 数归一化平均 log-likelihood，排除 prompt 和 EOS。选择分数最高的策略作为 meta-label。若分数差在 1e-6 容差内，按 Similar > Balanced > Diverse 固定顺序打破平局。

Validation/Test 的 gold label 不参与 selector 训练。该似然目标与最终 greedy 0/1 分类正确性并不完全等价，报告会提供 meta-label 分布和 score-margin 诊断。

02 官方 Test 最终结果

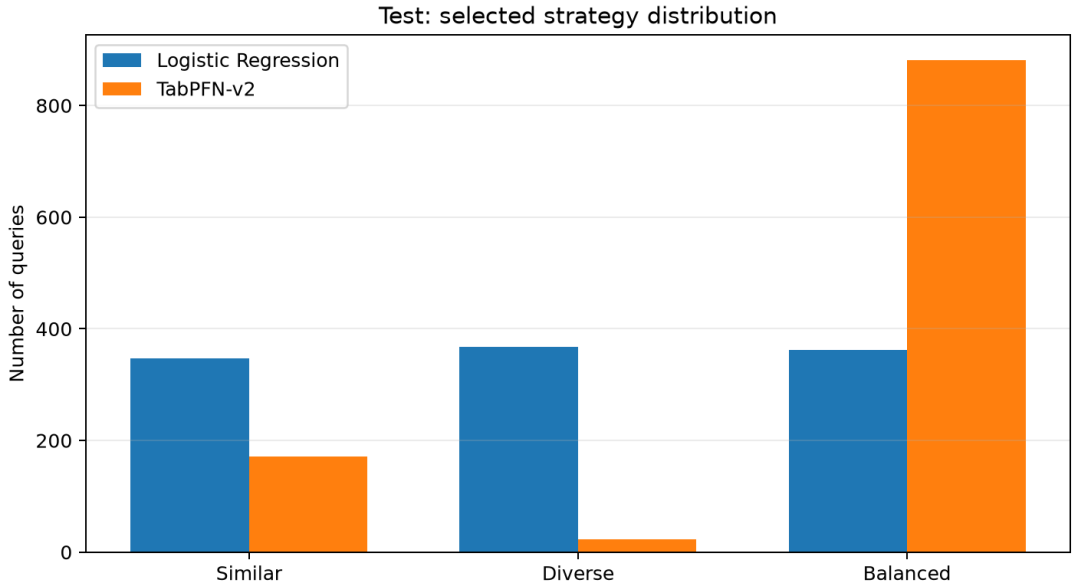
方法	正确数	Accuracy	Macro-F1	Invalid
Similar	910/1,076	84.572%	0.82895	9
Diverse	913/1,076	84.851%	0.84148	6
Balanced	925/1,076	85.967%	0.84760	2
Logistic Regression	917/1,076	85.223%	0.84320	7
TabPFN-v2	926/1,076	86.059%	0.84873	3
Oracle（事后上界）	967/1,076	89.870%	0.88834	2



解读：Oracle 的每条 query 都在观察三种策略的真实正确性后选择，因此是不可部署的 retrospective upper bound。不能将其作为模型结果。

03 策略切换与 Oracle 空间

选择器	策略选择分布	有益切换	有害切换	净增正确
LR	{'diverse': 367, 'similar': 347, 'balanced': 362}	21	14	+7
TabPFN-v2	{'balanced': 882, 'diverse': 23, 'similar': 171}	36	20	+16



Meta-training 的三策略 likelihood 最高分与第二高分的平均差为 0.084024；49 条 query 在 1e-06 容差内并列。似然标签与最终 greedy 分类正确性并非完全等价，因此仍需结合下游有益/有害切换数解读。

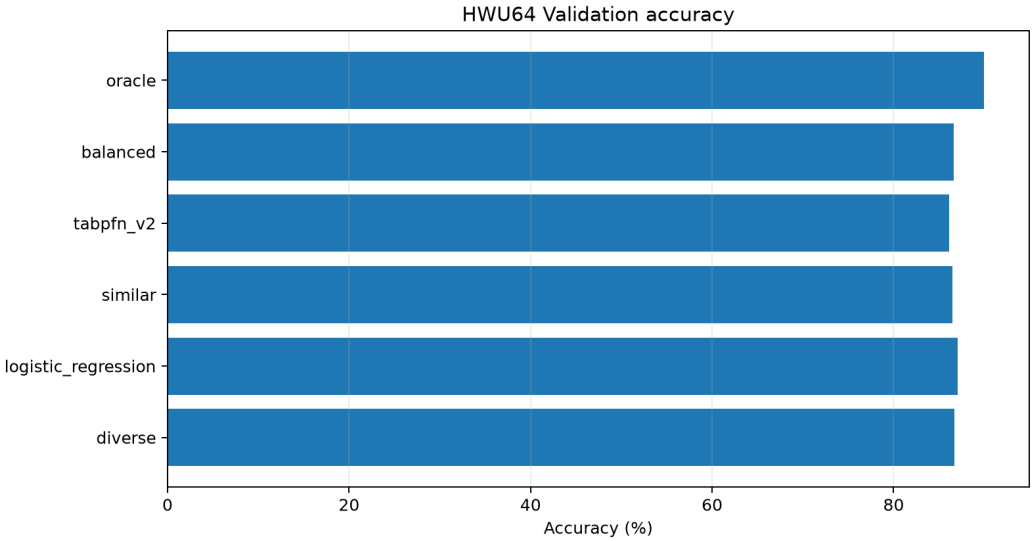
04 配对统计检验

使用 Query-level paired bootstrap（固定 seed；5,000 次重抽样）估计 Accuracy 差值的 95% 置信区间；采用双侧 Exact McNemar 检验，并对四个相对 Similar 的比较进行 Holm 校正。

比较	Δ Accuracy (pp)	95% Bootstrap CI	McNemar p	Holm p
diverse - similar	+0.279	[-1.394, +1.952]	0.8284	0.8284
balanced - similar	+1.394	[-0.186, +3.067]	0.1284	0.3852
logistic_regression - similar	+0.651	[-0.372, +1.673]	0.3105	0.6210
tabpfn_v2 - similar	+1.487	[+0.093, +2.881]	0.0440	0.1762

Validation 与 Official Test

方法	Validation	Test	Test - Val (pp)
Similar	86.480%	84.572%	-1.908
Diverse	86.704%	84.851%	-1.853
Balanced	86.592%	85.967%	-0.626
Logistic Regression	87.039%	85.223%	-1.816
TabPFN-v2	86.145%	86.059%	-0.086
Oracle（事后上界）	89.944%	89.870%	-0.074



05 讨论、局限与可复现性

结果解释边界

1. 本次结果只适用于 HWU64 当前数据快照、指定 Qwen checkpoint、all-MiniLM-L6-v2 与三种固定的 8-shot 选择策略。

2. 监督目标采用 gold-label token mean log-likelihood argmax，与最终 greedy 0/1 correctness 并不完全等价；应结合标签比例和 score margin 检查目标质量。

3. Selector 训练诊断：{'logistic_regression': {'nested_oof_accuracy': 0.3657174762702401, 'nested_oof_macro_f1': 0.365657927312395, 'best_parameters': {'classifier__C': 1.0, 'classifier__class_weight': 'balanced'}, 'folds': 5, 'validation_used_for_tuning': False, 'class_counts': {'0': 576, '1': 577, '2': 638}}, 'tabpfn': {'device': 'mps', 'version': 'v2', 'n_estimators': 4, 'checkpoint': {'repository': 'Prior-Labs/TabPFN-v2-clf', 'revision': '275f19d2add9c2c0de38f9ebaded3856599fa2e7', 'filename': 'tabpfn-v2-classifier-finetuned-zk73skhh.ckpt', 'sha256': 'cf8c519c01eaf1613ee91239006d57b1c806ff5f23ac1aeb1315ba1015210e49'}, 'n_training_rows': 1791, 'class_counts': {'0': 576, '1': 577, '2': 638}, 'actual_devices': ['mps'], 'package_version': '9.2.0'}}。若 meta-target 只有一个类别，程序会明确记录 majority-class fallback，而不会伪称训练出了可切换的多类 selector。

4. Oracle 是使用 gold label 事后挑选策略的上界，不代表实际系统可以达到。

5. Test 结果只可用于最终评估，不应用来反复调参或重新选阈值。

可复现性记录

项目	记录
Dataset	DeepPavlov/hwu64 @ local-arrow-cache-0dd289ccdeb185ec065d1ebcf5de1c443cd1620f
Split	seed=42；70/20/10 stratified train split
Embedding	sentence-transformers/all-MiniLM-L6-v2 @ 1110a243fdf4706b3f48f1d95db1a4f5529b4d41
LLM	Qwen/Qwen2.5-1.5B-Instruct @ 989aa7980e4cf806f80c7fef2b1adb7bc71aa306
Selection	Top-32; k=8; MMR λ=0.5
Selector	LR + pinned TabPFN-v2 checkpoint

主要输出：results/evaluation.json、results/meta_training_dataset.csv、results/meta_label_scores.jsonl、validation/test predictions CSV、cache/scores/、cache/predictions/ 和本 PDF 报告。